MILESTONE P3

FROM UNDERSTANDING TO PREPARATION
TỪ HIỂU DỮ LIỆU ĐẾN CHUẨN BỊ DỮ LIỆU

Data Understanding, Data Quality Assessment & Reproducible Data Preparation

Lĩnh vực bắt buộc: GIÁO DỤC

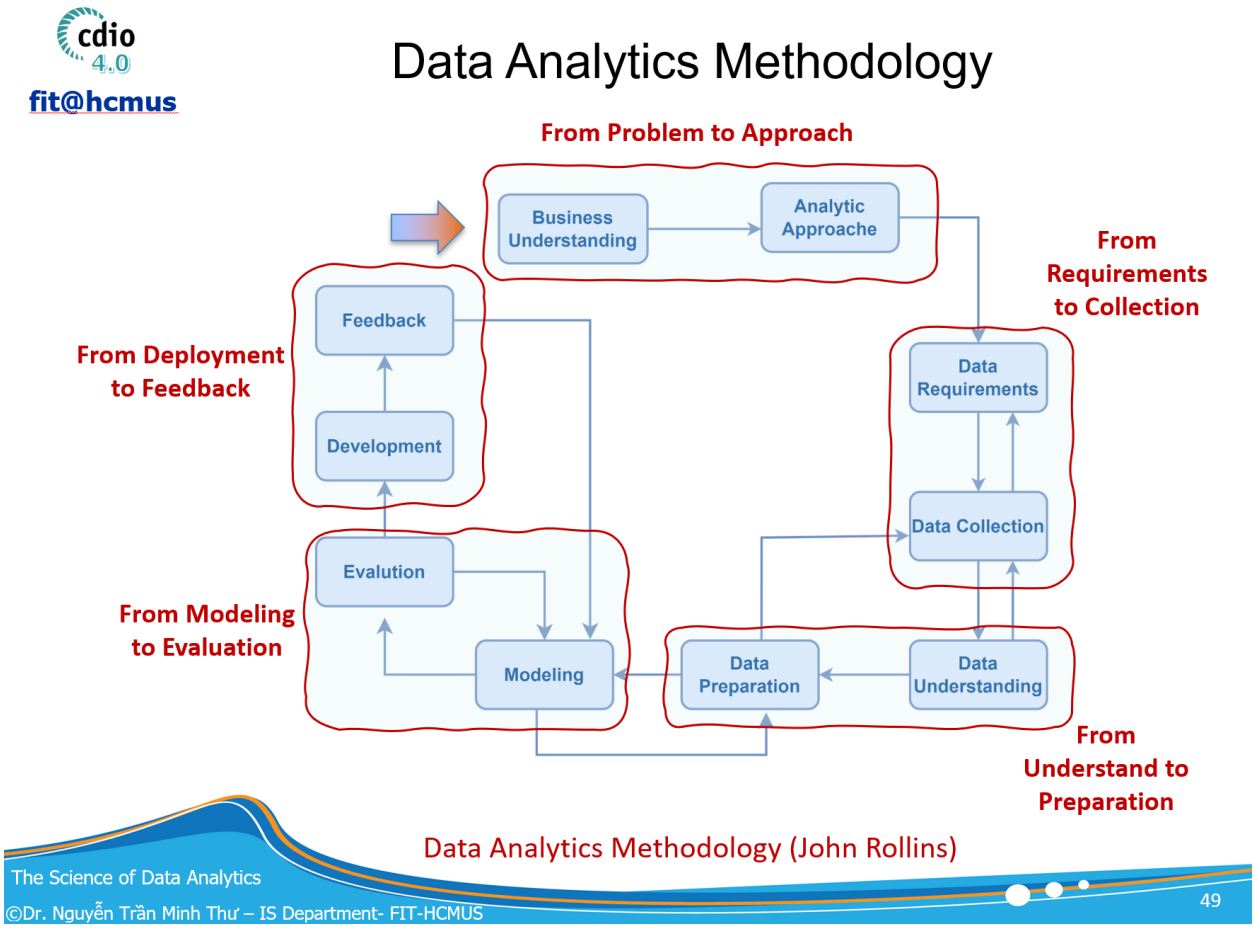
Mục tiêu của Milestone 3
Kiểm chứng mức độ phù hợp và chất lượng của bộ dữ liệu mở đã thu thập ở Milestone 2; hiểu cấu trúc, nội dung, giới hạn và các vấn đề chất lượng dữ liệu; sau đó xây dựng một quy trình chuẩn bị dữ liệu có thể tái lập để tạo Analytic-ready Dataset làm đầu vào cho giai đoạn Modeling & Evaluation.

Thông tin nhóm	Nội dung
Tên nhóm	
Thành viên	
Project title	
Milestone 1 version	
Milestone 2 dataset/version	
Prepared dataset version	
Ngày nộp	

Tài liệu hướng dẫn thực hiện đồ án – Student Project Guideline

1. Vị trí của Milestone 3 trong Data Analytics Methodology

Milestone 3 tương ứng với giai đoạn **From Understanding to Preparation** trong Data Analytics Methodology. Đây là cầu nối giữa dữ liệu đã thu thập và dữ liệu sẵn sàng cho phân tích/mô hình hóa.



Hình 1. Vị trí Milestone 3 trong Data Analytics Methodology (John Rollins)

Milestone	Câu hỏi trung tâm	Đầu ra chính
Milestone 1 – From Problem to Approach	Vấn đề nào cần giải quyết? Câu hỏi phân tích nào cần trả lời?	Business Goal, SMART Goal/KPI, Analytical Questions, Analytics Type, Decision Supported.
Milestone 2 – From Requirements to Collection	Để trả lời các câu hỏi đó cần dữ liệu gì? Dataset mở nào thực sự cung cấp dữ liệu cần thiết?	Data Requirements, dataset selection, raw data, provenance, requirement coverage.
Milestone 3 – From Understanding to Preparation	Dữ liệu thật sự chứa gì, chất lượng ra sao, cần xử lý như thế nào và có còn trả lời được các câu hỏi đã cam kết không?	Data Understanding Report, Data Quality Decisions, Preparation Pipeline, Analytic-ready Dataset, Model Readiness.

Nguyên tắc xuyên suốt
Milestone 3 không phải là bước "làm sạch dữ liệu cho đẹp". Mọi quyết định chuẩn bị dữ liệu phải có lý do gắn với Analytical Question, loại phân tích, cấu trúc dataset và rủi ro làm sai lệch kết quả.

2. Mục tiêu học tập và mục tiêu project

Sau khi hoàn thành Milestone 3, nhóm phải chứng minh được các năng lực sau:

- Hiểu và mô tả dataset ở mức schema, semantics, unit of analysis, keys, target/outcome, thời gian và quan hệ giữa các bảng/file.
- Đánh giá chất lượng dữ liệu bằng bằng chứng: missingness, duplicates, invalid values, outliers, class imbalance, temporal coverage, join integrity và các vấn đề consistency.
- Đánh giá lại độ phù hợp giữa dữ liệu thực tế và các Analytical Questions ở bốn mức Descriptive, Diagnostic, Predictive và Prescriptive.
- Phân biệt "missing values" với "missing variables/concepts" và chọn cách xử lý phù hợp, không tạo bằng chứng giả để lấp khoảng trống dữ liệu.
- Thiết kế và thực thi một Data Preparation Pipeline có thể tái lập, giữ được lineage từ raw data đến prepared data.
- Nhận diện và kiểm soát data leakage, target leakage, bias/representativeness và các rủi ro đạo đức trong dữ liệu giáo dục.
- Sử dụng Generative AI như partner hỗ trợ hiểu dữ liệu, viết mã và phản biện quyết định, nhưng không để AI thay thế việc kiểm chứng bằng dữ liệu thật.

3. Đầu vào bắt buộc từ Milestone 2

Nhóm chỉ bắt đầu Milestone 3 khi đã có một **Data Collection Package** đủ tối thiểu. Nếu còn thiếu nguồn, license hoặc raw file, phải hoàn thiện Milestone 2 trước.

Đầu vào	Yêu cầu
Milestone 1 baseline	Business Goal, SMART Goal/KPI, Analytical Questions, Analytics Type và Decision Supported phiên bản đang hiệu lực.
Updated Traceability Matrix	AQ → Data Requirement → Dataset/File → Actual Variables → Coverage/Gap.
Raw Data Package	File nguyên gốc được giữ bất biến trong data/raw; không chỉnh sửa trực tiếp.
Metadata / Data Dictionary	Mô tả biến, codebook, bảng quan hệ, đơn vị đo, license/citation và nguồn chính thức.
Collection Evidence	URL/DOI, access date, version, checksum/file size hoặc bằng chứng provenance tương đương.
Controlled Change Log	Mọi điều chỉnh từ Milestone 1/2 đã được ghi lại và có rationale.

Entry Gate
Nếu dataset chỉ hỗ trợ một phần rất nhỏ của proposal, nhóm không nên tiếp tục cleaning/modeling chỉ vì đã tải được dữ liệu. Trước hết phải thực hiện Task 3 của Milestone này để quyết định giữ, sửa, thay hoặc loại câu hỏi phân tích.

4. Nguyên tắc làm việc trong Milestone 3

Nguyên tắc	Yêu cầu thực hiện
Understand before Prepare	Phải hiểu ý nghĩa, phạm vi và chất lượng dữ liệu trước khi sửa/xóa/biến đổi.
Raw is immutable	Không chỉnh sửa file trong data/raw. Mọi xử lý tạo file/version mới trong data/interim hoặc data/processed.
Question-driven preparation	Chỉ thực hiện biến đổi có mục đích liên quan đến AQ, KPI, target hoặc kỹ thuật dự kiến.
Evidence before assumption	Không suy diễn ý nghĩa biến chỉ từ tên cột; đối chiếu documentation, distribution và logic domain giáo dục.
Reproducibility	Mọi bước xử lý phải có code/notebook hoặc mô tả đủ để người khác tái lập.
No silent revision	Nếu dữ liệu buộc phải đổi AQ/SMART scope, phải cập nhật Controlled Change Log.
No modeling yet	Milestone này có thể chuẩn bị split/feature structure, nhưng chưa tối ưu mô hình và chưa dùng model performance để "chọn" cách cleaning trên toàn bộ dữ liệu.

5. Quy trình thực hiện Milestone 3

Bước	Hoạt động	Sản phẩm
1	Reconfirm scope, dataset, unit of analysis, target và keys.	Dataset Understanding Map
2	Thực hiện Data Profiling & Data Quality Assessment.	Data Understanding Report
3	Đối chiếu AQ với bằng chứng dữ liệu thật; xử lý data gaps.	AQ–Data Fit Decision Log
4	Xây Data Preparation Plan trước khi thay đổi dữ liệu.	Preparation Decision Matrix
5	Thực thi cleaning, integration, transformation và feature construction.	Reproducible Preparation Pipeline
6	Kiểm tra leakage, bias, data quality sau xử lý.	Prepared Data Validation Report
7	Đóng gói analytic-ready dataset và data dictionary phiên bản mới.	Prepared Dataset Package
8	Đánh giá readiness theo 4 mức analytics và cập nhật proposal.	Model Readiness + Revised Traceability

6. Task 1 – Hiểu cấu trúc và ý nghĩa dữ liệu

Trước khi EDA hoặc cleaning, nhóm phải mô tả dataset theo **ngữ nghĩa của domain giáo dục** chứ không chỉ theo tên cột.

Nội dung cần xác định	Câu hỏi hướng dẫn
Population	Dữ liệu đại diện cho ai/cái gì? Sinh viên nào, bậc học nào, khóa học nào, thời gian nào?
Unit of analysis	Một record đại diện cho student, student-course, student-week, assessment, event hay một đơn vị khác?
Primary/foreign keys	Khóa nào xác định duy nhất record? Có cần composite key? Quan hệ giữa các bảng là 1–1, 1–N hay N–N?
Outcome / target	Biến kết quả được định nghĩa thế nào? Có phải outcome thật hay proxy? Khi nào outcome được quan sát?
Time semantics	Date/time/week nghĩa là thời điểm event, deadline, submission hay snapshot? Có timezone/relative week?
Measurement semantics	Score, engagement, completion, attendance... được tính như thế nào? Đơn vị và thang đo?
Categorical codes	Các mã category có mapping rõ trong codebook không? Có “unknown/other/not applicable”?
Sensitive attributes	Có gender, age, disability, socioeconomic status, location hoặc nhóm dễ bị tổn thương không?

6.1. Dataset Understanding Map bắt buộc

File/Table	Unit of Analysis	Primary Key	Foreign Key	Main Variables	Time Field	Role in AQ

7. Task 2 – Data Profiling & Data Quality Assessment

Data Understanding phải dựa trên **evidence** từ dữ liệu. Nhóm cần tạo các bảng/tóm tắt/visualization cần thiết để mô tả những vấn đề sau.

Khía cạnh	Phải kiểm tra	Câu hỏi phản biện
Shape & schema	Rows/columns, types, identifiers, table relationships.	Shape có phù hợp documentation? Có grain bị hiểu sai?
Missingness	Tỷ lệ missing theo biến/nhóm/thời gian; pattern đồng xuất hiện.	Missing có ngẫu nhiên? Có tập trung ở một nhóm sinh viên/course?
Duplicates & key integrity	Duplicate rows, duplicate keys, orphan foreign keys.	Duplicate là lỗi hay là nhiều event hợp lệ?
Validity / consistency	Range, category codes, impossible dates, inconsistent formats.	Giá trị nào vi phạm rule/domain?
Distribution	Center, spread, skewness, zero inflation, rare categories.	Distribution có ảnh hưởng đến cách phân tích/biến đổi?
Outliers	Giá trị cực đoan theo thống kê và theo domain.	Outlier là lỗi hay là trường hợp thật cần giữ?
Target / outcome balance	Frequency/rate của outcome hoặc class.	Có imbalance nghiêm trọng? Minority class có đủ quan sát?
Temporal coverage	Khoảng thời gian, density theo tuần/tháng, gaps.	Có đủ lịch sử cho trend/prediction point?
Join integrity	Coverage sau join, unmatched keys, many-to-many explosion.	Join có làm nhân bản record hoặc làm mất nhóm nào?
Representativeness	Population, course, institution, country, mode of study.	Có thể khái quát kết quả đến bối cảnh project không?

7.1. Data Quality Issue Log

Issue ID	Variable/Table	Evidence	Impact on AQ	Severity	Decision
DQ01				High/Med/Low	
DQ02				High/Med/Low	
DQ03				High/Med/Low	

8. Task 3 – Đánh giá lại AQ–Data Fit và xử lý Data Gap

Sau Data Understanding, nhóm phải cập nhật lại từng Analytical Question. Đây là điểm quyết định quan trọng: **không phải câu hỏi nào từ Milestone 1 cũng nên được giữ nguyên khi dữ liệu thật không hỗ trợ**.

Mức hỗ trợ	Ý nghĩa	Hành động
GREEN – Full support	Các biến, population, time window và quality đủ để trả lời AQ ở mức claim đã định.	Giữ AQ; chuyển sang preparation.
YELLOW – Partial support	Có dữ liệu liên quan nhưng thiếu phạm vi, biến phụ, granularity hoặc chất lượng chưa đủ.	Thu hẹp AQ, đổi claim, hoặc bổ sung dataset tương thích; ghi Change Log.
RED – Unsupported	Thiếu concept/variable/target/intervention quan trọng hoặc không thể xác lập đúng bằng dữ liệu hiện có.	Sửa/bỏ/defer AQ. Không được tạo “evidence” giả để giữ câu hỏi.

8.1. Quy trình ra quyết định khi dữ liệu không đáp ứng câu hỏi

- 1) Kiểm tra lại documentation và semantics: biến cần thiết có tồn tại dưới tên khác hoặc trong bảng khác không?
- 2) Kiểm tra có thể DERIVE biến một cách hợp lệ từ các trường thực tế hay không (ví dụ tính submission delay từ submission_date và deadline). Nếu có, phải mô tả công thức và giả định.
- 3) Kiểm tra có thể bổ sung một open dataset khác hay không. Chỉ hợp nhất nếu population, time, granularity và join logic tương thích; không ghép hai dataset chỉ vì "có cùng tên biến".
- 4) Nếu vẫn thiếu: thu hẹp scope, hạ mức claim hoặc rewrite AQ để phù hợp với bằng chứng thật.
- 5) Nếu câu hỏi là cốt lõi nhưng dữ liệu hoàn toàn không hỗ trợ: defer hoặc loại AQ và cập nhật proposal/traceability. Đây là lựa chọn đúng hơn so với tạo dữ liệu giả để chứng minh.
- 6) Synthetic data chỉ được xem xét cho mục đích THỰC NGHIỆM phương pháp/pipeline theo chính sách ở Mục 8.3, không thay thế dữ liệu bằng chứng.

8.2. Phân biệt Missing Value và Missing Variable

Tình huống	Ví dụ	Có thể xử lý thế nào?
Missing value – biến tồn tại nhưng một số record thiếu	Một số sinh viên không có survey satisfaction score.	Phân tích missingness; có thể loại, tạo category, hoặc impute nếu có cơ sở. Phải đánh giá ảnh hưởng/sensitivity.
Missing variable/concept – dataset không hề thu thập	Dataset không có thông tin intervention/support received nhưng AQ hỏi "can thiệp nào hiệu quả nhất?".	Không được impute/sinh giả như dữ liệu thật. Phải bổ sung nguồn dữ liệu hợp lệ hoặc sửa/defer AQ.
Missing target/label	Không có outcome dropout/completion nhưng project muốn supervised prediction.	Không thể huấn luyện supervised target thật. Cần dataset khác hoặc đổi loại bài toán.

8.3. Chính sách sử dụng Synthetic / Generative Data

Synthetic data không mặc định là "xấu", nhưng vai trò của nó phải được giới hạn rõ. Trong đồ án này, **synthetic data không được dùng để tạo bằng chứng thực nghiệm mà dữ liệu thật không có**.

Mức sử dụng	Trạng thái	Điều kiện bắt buộc
A. Pipeline / unit-test data	ĐƯỢC PHÉP	Dùng dữ liệu giả nhỏ để kiểm thử code, schema, ETL hoặc visualization. Phải gắn nhãn synthetic và không đưa vào kết luận.
B. Simulation / method demonstration	ĐƯỢC PHÉP CÓ ĐIỀU KIỆN	Có thể dùng để minh họa thuật toán hoặc scenario. Phải tách hoàn toàn khỏi real-data findings và ghi rõ assumptions.
C. Predictive data augmentation	CHỈ KHI ĐƯỢC GIẢNG VIÊN CHẤP THUẬN	Phải có baseline real-only, train augmentation chỉ trên training partition, đánh giá cuối cùng trên real holdout; báo cáo tác động và bias.
D. Fill a missing concept/label/intervention	KHÔNG ĐƯỢC PHÉP	Không tạo student records, target labels, demographic values hay intervention outcomes để "lấp" thứ dataset không thu thập.
E. Descriptive/diagnostic evidence	KHÔNG ĐƯỢC PHÉP	Không trộn synthetic data với real data để tính prevalence, trend, correlation hoặc kết luận về người học thật.

Quy tắc ưu tiên
Khi dữ liệu không hỗ trợ AQ, thứ tự ưu tiên là: (1) kiểm chứng/derive hợp lệ từ real data → (2) bổ sung nguồn real data tương thích → (3) thu hẹp/rewrite AQ → (4) defer/drop AQ. Synthetic data không phải là "bước 5 để cứu câu hỏi".

9. Task 4 – Xây dựng Data Preparation Decision Matrix

Trước khi sửa dữ liệu, nhóm phải lập một **Preparation Plan**. Mỗi thao tác cần nêu issue, rationale, method và rủi ro đối với kết quả.

Issue / Need	Decision	Rationale	Implementation	Validation
Missing values				
Duplicate / key issue				
Invalid category / type				
Outliers				
Table integration				
Derived feature				
Temporal aggregation				
Encoding / scaling				

9.1. Hướng dẫn quyết định theo loại vấn đề

Vấn đề	Không nên làm ngay	Cách tiếp cận đúng
Missing values	Impute tất cả bằng mean/0 mà không phân tích.	Xem tỷ lệ/pattern, ý nghĩa missing; chọn drop/category/imputation phù hợp và ghi sensitivity.
Duplicates	drop_duplicates() toàn bộ không kiểm tra.	Xác định grain và key; phân biệt duplicate lỗi với nhiều event hợp lệ.
Outliers	Xóa mọi điểm ngoài IQR.	Kiểm tra domain, data entry error, tail behavior; cân nhắc cap/transform/robust method/giữ nguyên.
Categorical values	Gộp category hiếm tùy ý.	Kiểm tra codebook; chỉ gộp khi hợp lý về domain và ảnh hưởng đến AQ/model.
Time	Dùng dữ liệu tương lai để tính feature quá khứ.	Cố định cut-off/prediction point; chỉ aggregate event trước thời điểm hợp lệ.
Sensitive attributes	Loại bỏ ngay mọi biến nhạy cảm nên không thể audit bias.	Xác định mục đích: có thể giữ để audit fairness nhưng hạn chế dùng làm predictor tùy bối cảnh và policy.

10. Task 5 – Thực thi Reproducible Data Preparation Pipeline

Pipeline phải chạy từ raw data đến prepared data một cách lặp lại được. Khuyến nghị tách các bước sau và lưu code/version rõ ràng.

1. Load raw files + validate file/schema assumptions.
2. Select in-scope population/records theo proposal.
3. Standardize data types, category labels, dates/times và identifiers.
4. Resolve key/duplicate issues theo grain đã xác định.
5. Handle missing values theo từng biến/nhóm và rationale đã duyệt.
6. Handle invalid values/outliers nếu cần; không xóa dữ liệu chỉ vì “trông lạ”.
7. Integrate tables/datasets với join validation và row-count checks.
8. Construct derived variables/features từ real fields; ghi công thức, window và timestamp rule.
9. Create analysis-ready tables theo từng mức analytics nếu cần (student-level, student-week, event-level...).
10. Persist prepared dataset, data dictionary, transformation log và validation summary.

10.1. Cấu trúc thư mục khuyến nghị

```
project/
  README.md
  data/
    raw/                  # bất biến
    interim/              # kết quả trung gian có thể tái tạo
    processed/            # analytic-ready dataset
    metadata/             # dictionary, lineage, quality logs
  notebooks/
    02_data_understanding.ipynb
    03_data_preparation.ipynb
  src/
    prepare_data.py
  reports/
    milestone3/
```

11. Task 6 – Kiểm soát Leakage, Split và các biến đổi phụ thuộc dữ liệu

Đây là yêu cầu đặc biệt quan trọng nếu proposal có **Predictive Analytics**. Nếu preparation sử dụng thông tin của test/future data, model evaluation ở Milestone 4 có thể bị lạc quan giả.

Rủi ro	Ví dụ trong giáo dục	Quy tắc
Target leakage	Dùng final grade, withdrawal date hoặc late-semester activity để dự báo risk ở tuần 4.	Feature chỉ được dùng nếu tồn tại trước prediction point.
Train-test contamination	Chuẩn hóa/impute bằng thống kê tính trên toàn dataset rồi mới split.	Split trước các transform cần "fit"; fit transform trên training và apply sang validation/test.
Student leakage	Cùng một sinh viên xuất hiện ở cả train và test trong bài toán cần generalize sang unseen students.	Chọn split theo entity phù hợp với claim.
Temporal leakage	Random split khi mục tiêu là dự báo học kỳ tương lai.	Cân nhắc temporal split/rolling validation.
Augmentation leakage	Synthetic samples được tạo từ toàn bộ data, kể cả holdout.	Nếu augmentation được duyệt, chỉ sinh từ training partition; holdout phải là real data.

Không "học" từ test set trong Milestone 3
Các lựa chọn cleaning/feature construction có thể dựa trên domain và training data. Không được lặp đi lặp lại nhìn test outcome để tối ưu preprocessing, vì như vậy test set không còn là đánh giá độc lập.

12. Task 7 – Chuẩn bị dữ liệu theo bốn mức Analytics

Một project có thể cần nhiều analytic-ready views thay vì một bảng duy nhất. Nhóm phải chỉ ra cấu trúc dữ liệu nào phục vụ từng mức câu hỏi.

Analytics Level	Prepared data cần có	Điểm kiểm tra trước Milestone 4
Descriptive	Population rõ, denominator đúng, measures/dimensions sạch, time grain phù hợp.	Có thể tạo summary/trend mà không double-count hoặc bias vì join.
Diagnostic	Descriptive view + explanatory factors + comparison groups; xử lý confound/context ở mức phù hợp.	Association được tính từ real data; không diễn giải association thành causation.
Predictive	Target rõ, prediction point, pre-point features, entity/time split, leakage-safe transforms.	Có đủ sample/target classes; target balance và split strategy hợp lý.
Prescriptive	Action/intervention/constraint/cost/outcome data hoặc bằng chứng đủ để đánh giá lựa chọn.	Nếu không đủ, chỉ giữ ở mức decision requirement/future work; không "nâng cấp" từ predictive thành prescriptive bằng lời khuyên AI.

12.1. Model Readiness Matrix

AQ	Analytics Type	Prepared View/Table	Target/Measure	Feature Set / Dimensions	Split/Time Rule	Readiness
AQ1						Ready / Revise
AQ2						Ready / Revise
AQ3						Ready / Revise
AQ4						Ready / Revise

13. Task 8 – Validate và đóng gói Prepared Dataset

Sau preparation, nhóm phải chứng minh rằng dữ liệu tốt hơn cho mục tiêu phân tích nhưng vẫn giữ được tính đúng đắn và traceability.

- So sánh row count / entity count / target distribution trước và sau xử lý; giải thích mọi thay đổi lớn.
- Kiểm tra lại missingness, key uniqueness, join coverage, invalid ranges và temporal order.
- Đối chiếu derived features với công thức/sample manual check.
- Xác nhận prepared data không chứa biến leakage so với prediction point.
- Cập nhật data dictionary với source field, transformation, datatype, role và sensitivity.
- Lưu version, code commit/notebook version, input raw version và timestamp tạo prepared dataset.

13.1. Data Lineage Table

Prepared Variable	Source File/Field	Transformation	Window/Filter	Purpose/AQ	Sensitivity

14. Sử dụng Generative AI như partner trong Milestone 3

Generative AI được phép hỗ trợ cả Data Understanding và Data Preparation, nhưng **mọi phát hiện về dữ liệu phải được xác nhận bằng code, thống kê, visualization, documentation hoặc kiểm tra trực tiếp trên dataset**.

Vai trò AI được phép	Ví dụ sử dụng	Giới hạn / kiểm chứng
Data dictionary interpreter	Giải thích ý nghĩa codebook, gợi ý câu hỏi cần kiểm tra về schema.	Không chấp nhận diễn giải nếu trái documentation hoặc data profile.
EDA / quality checklist partner	Gợi ý kiểm tra missingness, keys, outliers, imbalance, time coverage.	Nhóm phải tự chạy kiểm tra và báo evidence.
Code assistant	Draft Python/R/SQL cho profiling, cleaning, joins, transformations.	Phải review code, test trên sample, kiểm tra row counts và results.
Preparation critic	Phản biện imputation/outlier/encoding strategy và cảnh báo leakage.	Team quyết định cuối cùng và ghi rationale.
Feature engineering ideator	Gợi ý derived features từ fields đang có.	Chỉ dùng feature có thể tính từ real data và đúng prediction timing.
Documentation assistant	Hỗ trợ viết transformation log, README, data dictionary.	Không để AI bịa statistics, source field hoặc transformation đã không thực hiện.

Vai trò AI được phép	Ví dụ sử dụng	Giới hạn / kiểm chứng
Synthetic-data assistant	Tạo test records/pipeline fixtures; mô phỏng khi được phép.	Phải tuân thủ chính sách synthetic data ở Mục 8.3.

14.1. AI Decision Log bắt buộc

AI suggestion	Team decision	Accepted / Rejected	Evidence used to verify	Effect on pipeline

AI không phải một nguồn dữ liệu
Không được dùng câu trả lời của Generative AI để xác nhận "sinh viên có xu hướng…", "biến X gây ra Y", "dataset có N record", hoặc để tạo giá trị missing rồi coi đó là quan sát thật. AI là partner cho reasoning/coding; evidence phải đến từ dữ liệu và nguồn chính thức.

15. Ví dụ minh họa – Project về Course Completion

Ví dụ dưới đây minh họa cách nối Milestone 1 → 2 → 3. Không phải đáp án mẫu để sao chép.

Thành phần	Ví dụ minh họa
Business Goal	Cải thiện khả năng hoàn thành môn học của sinh viên trong môi trường học trực tuyến/blended.
AQ Descriptive	Completion rate thay đổi thế nào theo course/presentation?
AQ Diagnostic	Engagement và assessment behavior khác nhau thế nào giữa nhóm Complete và Withdraw/Fail?
AQ Predictive	Có thể dự báo sớm nguy cơ không hoàn thành ở cuối tuần 4 không?
Potential Data Gap	Dataset không có thông tin về loại hỗ trợ/can thiệp mà sinh viên đã nhận.
Decision for Prescriptive AQ	Không tạo synthetic intervention outcome. Giữ "Which intervention should be used?" như future requirement hoặc rewrite thành câu hỏi về nhóm cần ưu tiên hỗ trợ.
Preparation implication	Tạo student-week features chỉ từ events trước/tới tuần 4; giữ final outcome làm target; không dùng activity sau tuần 4 làm predictor.

16. Sản phẩm phải nộp cho Milestone 3

Nhóm nộp **01 báo cáo Milestone 3** và **01 Prepared Data Package**. Báo cáo nên khoảng 8–12 trang nội dung chính, không tính phụ lục, code và data files.

Deliverable	Nội dung bắt buộc
A. Milestone 3 Report	Dataset understanding; profiling; data quality issues; AQ–Data fit decisions; preparation decisions; validation; risks/limitations; AI usage.
B. Updated Traceability	Business Goal/SMART/KPI → AQ → Analytics Type → Raw Variables → Preparation → Prepared Variables/View → Decision Supported.
C. Preparation Pipeline	Notebook/script có thể chạy lại từ raw data; không thao tác thủ công không ghi nhận.
D. Prepared Data Package	data/processed + data dictionary + lineage + version/provenance + validation summary.
E. Controlled Change Log	Mọi AQ/scope/claim thay đổi do data understanding hoặc data gaps.
F. AI Decision Log	Prompt/suggestion quan trọng, team decision, evidence kiểm chứng, accepted/rejected.

16.1. Cấu trúc báo cáo khuyến nghị

Section	Nội dung
1. Project Baseline & Dataset	Tóm tắt M1/M2; dataset/version; scope; AQ hiện tại.
2. Data Understanding	Population, unit, schema, keys, target, time semantics, sensitive attributes.
3. Data Profiling & Quality	Missingness, duplicates, validity, outliers, distributions, target balance, temporal/join/representativeness.
4. AQ–Data Fit & Data Gap Decisions	Green/Yellow/Red; derive/add real data/rewrite/drop; synthetic-data decision nếu có.
5. Data Preparation Plan	Issue → decision → rationale → implementation → validation.
6. Data Preparation Pipeline	Cleaning, integration, transformations, feature construction, split/leakage rules.
7. Prepared Data Validation	Before/after checks, lineage, dictionary, residual risks.
8. Analytics / Model Readiness	Prepared views theo 4 analytics levels; target/features/split; questions còn chưa khả thi.
9. Ethics, Bias & Limitations	Sensitive variables, representativeness, fairness/audit use, limitations of claims.
10. Generative AI Usage & Reflection	AI roles, accepted/rejected suggestions, verification evidence.

17. Checklist trước khi nộp

- ☐ Raw data trong data/raw vẫn giữ nguyên và có provenance/version.
- ☐ Nhóm xác định đúng unit of analysis, keys, target/outcome và time semantics.
- ☐ Data profiling có bằng chứng cho missingness, duplicates, validity, outliers, target balance, time và joins.
- ☐ Mỗi data quality issue có decision và rationale, không cleaning theo thói quen.
- ☐ Nhóm phân biệt rõ missing values với missing variables/concepts.
- ☐ AQ không được "cứu" bằng synthetic data khi real data không hỗ trợ.
- ☐ Nếu có synthetic data, mục đích nằm trong chính sách cho phép và được tách khỏi real-data evidence.
- ☐ Predictive AQ có prediction point, split strategy và kiểm soát leakage.
- ☐ Transformations cần fit được fit trên training partition khi thích hợp.
- ☐ Derived features có công thức, source field, time window và lineage.
- ☐ Prepared data được kiểm tra lại row/entity counts, target distribution, missingness và key integrity.
- ☐ Traceability đã cập nhật từ AQ đến prepared variables/views thực tế.
- ☐ Có Data/Model Readiness Matrix cho Descriptive, Diagnostic, Predictive và Prescriptive.
- ☐ AI suggestions đã được kiểm chứng bằng dữ liệu/code/documentation và ghi AI Decision Log.
- ☐ Limitations và câu hỏi phải rewrite/drop/defer được trình bày minh bạch.

18. Thang đánh giá – 100 điểm

Tiêu chí	Điểm
Liên kết Milestone 1–2 và consistency của scope / Change Log	NA
Dataset Understanding: population, unit, keys, target, time, semantics	NA
Data Profiling & Data Quality Assessment có evidence	NA
AQ–Data Fit + quyết định xử lý data gaps / synthetic data hợp lý	NA
Data Preparation Decision Matrix và rationale	NA
Reproducible Preparation Pipeline + data lineage	NA
Leakage control / split strategy / predictive readiness	NA
Prepared Data Validation + analytics/model readiness	NA
Ethics, representativeness, sensitive attributes và limitations	NA
Generative AI usage có kiểm chứng, phản biện và AI Decision Log	NA
Tổng	100

19. Điều kiện chuyển sang Milestone 4 – From Modeling to Evaluation

Nhóm chỉ nên bắt đầu Modeling khi đáp ứng được các điều kiện sau:

- Ít nhất các Analytical Questions cốt lõi có Prepared Dataset/View phù hợp và traceability rõ.
- Target/measure và feature/dimension definitions đã ổn định đủ để model/analysis có ý nghĩa.
- Data leakage và split strategy đã được xác định cho predictive tasks.
- Các data quality issues quan trọng đã được xử lý hoặc được giữ lại có chủ đích và ghi limitation.
- Không còn sử dụng synthetic data như bằng chứng thay thế cho thông tin không tồn tại trong real data.
- Prepared data có thể tái tạo từ raw data bằng pipeline đã nộp.

Output cuối của Milestone 3
Một Analytic-ready Dataset không có nghĩa là dữ liệu "hoàn hảo". Nó có nghĩa là nhóm hiểu rõ dữ liệu, biết các giới hạn còn lại, đã chuẩn bị dữ liệu theo cách có lý do và tái lập được, và có thể giải thích vì sao dữ liệu này phù hợp với các phân tích/mô hình sẽ thực hiện ở Milestone 4.

END OF MILESTONE 3 GUIDELINE